

ベイズ的パルス逆畳み込みによる血管波形解析

Parker S. Ruth¹, Tommy DeBenedetti¹, Lily O'Brien¹, James A. Landay¹, Todd P. Coleman², Emily B. Fox^{1,3}

¹スタンフォード大学 計算機科学講座／²同 生体工学講座／³同 統計学講座 (Stanford, CA, USA) 責任著者:
paru@stanford.edu

原題: Vascular waveform analysis using Bayesian pulse deconvolution. bioRxiv. 2026-02-11. DOI:

10.64898/2026.02.09.699383 (査読前プレプリント、CC-BY 4.0)

全文和訳 (本文・図表説明を含む)

要旨

血管内の総流量を測定する血管波形 (vascular waveforms) は、バイタルサインの測定、病態の診断、長期健康転帰の予測に広く用いられている。血管波形の解析は、本質的に相互依存する3つの課題 — 信号のフィルタリング、拍タイミングの検出、脈波形状の抽出 — に依存する。

我々は、ベイズ的パルス逆畳み込み (Bayesian pulse deconvolution) がこれら3課題を同時に解くことで、すべてにおいて性能を改善しようと仮説を立てた。本手法は、物理学的・生物学的な領域知識に基づく事前分布を伴う、血管波形の解析的な生成モデルを用いる。

シミュレーションにおいて、ベイズ的パルス逆畳み込みは既存アルゴリズムと比較してすべての課題でより良い性能を達成した — フィルタリング誤差の中央値 90% 減、拍タイミング誤差 60% 減、形状抽出誤差 85% 減である。シミュレーションにおける優位性はヒトの光電容積脈波記録にも及ぶ。時刻同期した実際の心電図 R-R 間隔を代理の正解値とすると、ベイズ的パルス逆畳み込みは典型的アルゴリズム (RMSE = 8.3 ms) と比較して 40% 低い拍間隔推定誤差 (RMSE = 5.1 ms, $p = 1e-10$) を達成した。

血管波形からより正確で情報量の多い知見を抽出することにより、ベイズ的パルス逆畳み込みは血管からの信号解釈に依存する広範な健康技術を前進させうる。

序論

血管内の総流体輸送を測定する血管波形は、ヒトの身体から記録される最も普遍的かつ重要な信号の一つである。血管内血圧、血流速度、光電容積脈波、アプラーネーション・トノメトリを含むこれらの信号は、侵襲的血行動態モニタ [1-3]、非侵襲的ウェアラブルセンサ [4-6]、および多数の新興センサ [7] によって容易に取得できる。

血管波形は、単独で、あるいは他の測定と組み合わせて、健康の監視と疾患の検出に広く用いられている。心拍変動 [8]、血中酸素飽和度 [9]、血圧 [10-12]、血液量 [13]、心肺フィットネス [14] を含む多くの重要なバイタルサインを生じる。血管波形は不整脈 [15]、血行動態の代償破綻 [16]、動脈硬化 [17] といった心血管の健康問題を明らかにでき、さらには心臓発作・脳卒中・全死亡といった重要な健康転帰の予測にも役立ちうる [18,19]。

これらすべての応用は、センサデータにおける心拍のリズムと形状を臨床的に解釈することを要求する。これには3つの基本的な信号処理課題が含まれる。現行の実務では、これらの課題は典型的に逐次的なパイプラインで実行される [20-23]。

1. ノイズの多い信号のフィルタリングは、センサ誤差、ベースライン変動、アーチファクト、その他の非生理学的発生源から血管波形を分離するために重要である。これは線形デジタルフィルタ [24-29]、Savitzky-Golay フィルタ [29]、適応コムフィルタ [30,31]、あるいはニューラルネットワーク [32] によって実行されうる。
2. 拍タイミングの検出は、拍間間隔、心拍数、脈波伝播時間を抽出するために重要である。拍タイミングは典型的に、濾波された血管信号の 0 次・1 次・2 次微分の局所極値によって測定される [33-35]。

3. 脈波形状の抽出は、血中酸素飽和度、動脈スティフネス、血圧といった健康指標の算出に重要である。これは典型的に、セグメンテーションと脈波の平均化によって実行される [22, 23]。

各段階におけるアルゴリズムの選択は、波形解析パイプライン全体を通じて伝播する帰結をもつ。

我々は血管波形を、波の重ね合わせという物理的原理 [41] に基づき、拍時刻とインパルス応答の畳み込みとしてモデル化する。データと領域知識を組み合わせることでモデル内の観測不能変数に対するベイズ事前密度を設計し、観測信号を条件とするベイズ事後密度を計算する。

本研究は血管波形解析への統一的アプローチを提示する。従来、逆畳み込み法は神経活動 [42] や血中酸素濃度依存性機能的磁気共鳴 [43] といった、他のスパースまたは半周期的な生体信号の解析のために提案されてきた。関連研究には心血管生体信号のための生成 AI モデル [44] を提案したものもある。他の関連研究は、適応的テンプレート照合フィルタ [45] のため、あるいは心臓波形と血管波形の複合をインパルス列とインパルス応答に分解するため [46, 47]、非ベイズ的な反復アルゴリズムを提案した。しかしながら、これらの手法は血管波形に対する領域根拠のある事前分布を欠いている。

合成血管波形のシミュレーションのための確率モデルも提案されているが [48-50]、これらのモデルはベイズ推論によるヒト記録の処理には適していない。そこで我々は、血管波形に対してフィルタリング・タイミング検出・形状抽出を同時に解くベイズ的パルス逆畳み込みアルゴリズムを提案する。

結果

我々は、信号フィルタリング、拍タイミング検出、脈波形状抽出について、ベイズ的パルス逆畳み込みと従来アルゴリズムの精度を比較した。これらの課題について許容できる正解ラベルが存在しないため、まず -20 dB のガウスノイズを付加した 64 Hz サンプリングの 11 秒波形 100 本のシミュレーションでアルゴリズムを評価した。これらのシミュレーションにより、元のノイズなし信号、正確な拍時刻、分離された脈波形状に対して評価できる。次に、ヒト記録の実験データセットへのベイズ的パルス逆畳み込みの適用を示す。

信号フィルタリング

血管波形は典型的に線形時不変フィルタで濾波され、これは周波数依存の伝達関数によって特徴づけられる。これらのフィルタは信号とノイズが周波数領域で分離可能であることを仮定するが、これは一般に真ではない（例えば白色ガウスノイズは全周波数にわたって一様なパワーをもつ）。したがって線形フィルタは、ノイズを不完全にしか減衰させないか、望ましい信号を部分的に減衰させてしまう。

さらに、一般に用いられる無限インパルス応答 (IIR) フィルタは通過帯域内で位相遅延を導入するため、そのノイズ減衰効果を上回る信号歪みを引き起こしうる (図1a)。対照的にベイズ的パルス逆畳み込みは、解析モデルの最大事後確率 (MAP) 推定を求めることによりノイズなし信号を復元し (図1b)、周波数領域でのノイズ分離に関する仮定を一切置かない。

我々は、先行文献で報告された「最適」フィルタ [27, 36] および標準的な公刊済み血管波形解析アルゴリズム [21, 22] を代表するベースラインに対して、ベイズ的パルス逆畳み込みのノイズ減衰を比較した。100 回のシミュレーションにわたって、従来のフィルタはノイズ減衰の中央値 10~12 dB を達成したのに対し、ベイズアルゴリズムは中央値 31 dB のノイズ減衰を達成し、これは誤差信号パワーの 90% 削減に相当する (図1c)。フィルタリング性能の改善は、信号長・サンプリングレート・ノイズ水準にわたって成立する (補足図1)。

拍タイミング検出

典型的には、拍時刻は濾波された信号上のヒューリスティックなマーカーによって検出される。一般的なヒューリスティックマーカーは、信号の 0 次・1 次・2 次微分の局所極値である (図2a)。これらのマーカーは脈波形状の局所的特徴のみを用いるため、測定ノイズとフィルタ歪みに対して鋭敏である。対照的にベイズ的パルス逆畳み

込みは、隣接する脈波間の重なりを考慮しつつ、波形全体からの情報を用いて拍タイミングを決定する（図2b）。

100 回のシミュレーションにおいて、ベイズ的パルス逆畳み込みと、PyPPG Python パッケージ [22] に実装された4つの一般的なヒューリスティックマーカを用いて、拍時刻を推定し結果として得られる拍間間隔を測定した。

■ SP: 信号の局所最大値（収縮期ピーク）

■ ON: 信号の局所最小値（立ち上がり点）

■ U: 1 次微分の局所最大値（速度）

■ A: 2 次微分の局所最大値（加速度）

先行文献で報告されているとおり [33, 37]、1 次微分ピーク (U) が拍間間隔を最も正確に測定した (RMSE 中央値 = 12.0 ms)。ベイズ的パルス逆畳み込みはこの誤差を 60% 削減した (RMSE 中央値 = 4.9 ms) (図2c)。拍タイミング検出の改善は、信号長・サンプリングレート・ノイズ水準にわたって成立する（補足図1）。

ヒューリスティックマーカのタイミング精度は、上流のフィルタ歪みによって影響されうる。ヒューリスティックマーカに起因する誤差とフィルタ歪みに起因する誤差を区別するため、理想的なノイズなし信号から 1 次微分ピークを抽出した。この場合でもヒューリスティックマーカはベイズ的パルス逆畳み込みより高い誤差 (RMSE = 6.4 ms) を示した ($p = 1e-5$)。

脈波形状抽出

典型的には、脈波形状はヒューリスティックな拍タイミングマーカに基づいて波形をセグメント化することにより抽出される（図3a）。脈波を平均化することにより、この手法は相当なノイズ減衰を達成できる。しかしながら、ヒューリスティックな拍時刻の誤差は抽出される形状の解像度に影響しうる。さらに、隣接する心拍の重なりは抽出される脈波形状の歪みと切断を引き起こす。対照的にベイズ的パルス逆畳み込みは、重なり合う脈波を考慮しつつ、基礎にある脈波形状の全体を解析関数として復元する（図3b）。

我々は脈波形状抽出の精度を、真の脈波形状の総面積に対する誤差の総面積百分率に基づいて評価した。この指標（方法に定義）は脈波の輪郭の誤差と脈波の誤った切断の両方を捉える。

100 回のシミュレーションにわたって、典型的な脈波形状抽出法は誤差の中央値 48~49% を達成したのに対し、ベイズ的パルス逆畳み込みは 6.9% の誤差の中央値を達成し、これは形状抽出誤差の 85% 削減に相当する（図3c）。

※ 従来の脈波形状抽出法の精度は、上流のフィルタリングと拍タイミング誤差によって影響されうる。セグメンテーションと平均化のみに起因する誤差を分離するため、理想的なノイズなし信号と、シミュレーションからの正確な拍時刻に形状抽出を適用した。この場合、抽出形状の誤差の中央値は他のベースラインに対して改善しなかった。これは、誤差が主としてこの形状抽出法に内在する脈波の重なりと切断に起因することを示している。

ヒト記録における評価

シミュレーションにおけるベイズ的パルス逆畳み込みの優位性が実データでのより良い性能に翻訳されるかを検証するため、ヒト記録を用いた。手首装着の光電容積脈波波形から、ゴールドスタンダードである ECG に基づく R-R 間隔を推定する能力を評価した（図4a）。これはウェアラブルの心拍監視と不整脈検出に本質的な課題である [51, 52]。

ベイズ的パルス逆畳み込みは、従来法では正確に捉えられない、低振幅の洞性不整脈パターンといったサンプリングレート未満の心拍タイミングの変化を検出できる（図4b）。仰臥位・座位・立位・歩行・走行の条件下にある 21 名からの 105 記録について、最良性能の従来型拍タイミング法とベイズ的パルス逆畳み込みを比較した（図4c）。従来型拍タイミング法が RMSE 中央値 8.3 ms を達成したのに対し、ベイズ的パルス逆畳み込みは RMSE 中央値 5.1 ms を達成し、40% の誤差削減となった。

不確実性の定量化

最大事後確率解を生成することに加えて、ベイズ的枠組みは解空間にわたる不確実性を記述する完全な同時事後分布の計算も可能にする。事後の不確実性はサンプリングレートと信号対雑音比 (SNR) に対して期待どおりに応答する。高サンプリングレート・高 SNR の信号は高い確実性をもつ (図5a)。低サンプリングレート (図5b) または低 SNR (図5c) のいずれかの信号は中程度の確実性をもつ。両方が低い信号は低い確実性をもつ (図5d)。

考察

シミュレーション実験は、既存の血管波形解析法と比較した、ベイズ的パルス逆畳み込みによる信号フィルタリング・タイミング検出・形状抽出の同時解決の優位性を実証している。ベイズ的パルス逆畳み込みは信号歪みを導入することなくより良いノイズ減衰を達成し、より細かい解像度で拍タイミングを検出し、重なり合う心拍を切断することなく個々の脈波形状を抽出する。

シミュレーションはアルゴリズムを正確な真値に対して評価するために必要であるが、必然的に実際の血管波形を代表しない単純化の仮定を置く。シミュレーションの結果がヒト記録にどのように一般化するかを考慮することが重要である。シミュレーション波形は、ヒト記録から導出したベイズ事前密度からサンプリングすることにより可能な限り現実的になるよう設計された。さらに、ベイズ的パルス逆畳み込みの優位性はヒト記録で評価しても持続する。

タイミング精度を正しく評価するには精密に時刻同期した ECG が必要であるため、生の血管波形の大規模なコレクションである Aurora-BP データセット [53] を用いて評価を実施した。精密な拍タイミングは、不整脈の正確な検出および心拍変動の高周波成分の正確な測定に重要である [8]。今後の研究では、フィルタリングと形状抽出の機能を活用する下流の応用においてベイズ的パルス逆畳み込みを評価すべきである。

ベイズ事前分布は、拍間隔推定精度の評価に用いたのと同じヒト記録データセットから導出した。しかしながら、事前分布は被験者の部分集合のトノメトリ波形を用いて当てはめられ、評価は重複しない被験者の部分集合の光電容積脈波波形で実行されたため、ベイズアルゴリズムが不当に有利になってはいない。

脈波形状係数 w に対する事前分布は、従来のセグメンテーションと平均化法を用いて抽出した脈波形状を用いてヒト記録に当てはめられた。脈波形状抽出の誤差が形状事前分布に問題のある歪みをもたらしたかを検証するため、素朴な事前分布でベイズ的パルス逆畳み込みを実行し、MAP 脈波形状に対して形状事前分布を再当てはめする事前分布ブートストラップ法を検証した。ベンチマークにおけるアルゴリズム性能に有意な変化は認められず、元のデータ駆動型事前分布が妥当であったことが示唆された。

利点

性能の改善を超えて、ベイズ的パルス逆畳み込みは他の利点も提供する。推論された変数にわたる完全な同時事後密度により不確実性を定量化し、これは血中酸素や血圧といった下流の導出指標の不確実性へ伝播させることができる。任意のタイミングをもつ観測に解析信号を当てはめるため、リサンプリング、補間、欠測補完、外挿の課題を解くために転用できる。これらの強みは、使用不能なデータの散発的な窓をもつ信号 (例: 体動アーチファクトのあるウェアラブル信号) や、適応的サンプリングレート (例: 電力最適化された長期連続監視パッチ) にとって重要でありうる。

ベイズ的枠組みのもう一つの重要な利点は、異なるモデリング仮定への拡張性である。例えば、平均心拍数一定という仮定を緩め、散発的な不整脈イベントや呼吸性心拍変動をモデル化できる。拍タイミングのモデルを、統計的な適合度で測ってより心拍動態を捉える時間的点過程 [54, 55] に置き換えられる。静的な脈波形状という仮定を緩め、時間変化する脈波形状に対応できる。脈波形状の多変量ガウス事前分布を、正規化流 [56] のようなより柔軟なデータ駆動型密度推定に置き換えられる。ガウスノイズの仮定を、センサ固有のノイズプロファイルや散発的な体動アーチファクトに対応するよう修正できる。

本研究は血管内の総流量を測定する血管波形のみを扱うが、本手法は、心臓の興奮と収縮を測定し異なる形態をもつ心臓波形（例：心電図、心音図、心弾動図、心振動図）へ拡張できる。加えて、ベイズ事前分布を人口統計学的因子や過去の測定に基づいて個人ごとに個別化できる。

限界

ベイズ的パルス逆畳み込みは有望であるが、ここで提示した実装にはいくつかの実務的限界がある。

- 信号の半周期性に起因する多峰性の課題は、信号長が長く脈波数が多い信号に対して組合せ的にスケールする。これは、長い時系列における推論をスケールさせるバッファ付き確率的勾配マルコフ連鎖モンテカルロや変分推論のアプローチ [57] によって対処する。
- 今後の研究では、被験者ごと・記録ごとの階層モデリングにより脈波形状が時間とともに変化することを許容すべきである。
- さらなる最適化により推論速度を改善してリアルタイム応用を可能にする必要がある。

これらの課題を踏まえると、従来の血管波形解析アルゴリズムは決して時代遅れではない。極端な精度を要求しない用途では、ベイズ的パルス逆畳み込みは正当化されないかもしれない。例えば、頻脈・徐脈・心房細動といった主要な不整脈イベントの検出には、心拍間隔の粗い推定で十分でありうる。

しかしながら、ベイズ的パルス逆畳み込みは、高いタイミング精度を要する応用（例：心拍の自律神経性調節の測定）、高いノイズ低減を要する応用（例：遠隔光電容積脈波法）、高い形状抽出精度を要する応用（例：非侵襲的血压推定）に有意な影響を与えうる。これらおよび他の下流応用に対してベイズ的パルス逆畳み込みを検証するには、さらなる研究が必要である。

とはいえ、実証された利点は有意であり、血管波形解析の技術水準を前進させるものである。信号フィルタリング・タイミング検出・形状抽出を統一されたアルゴリズムで同時に解くことにより、本手法は従来の逐次パイプラインと比較して優れた性能を達成する。血管波形からより正確な知見を抽出するこの能力は、自律神経機能の測定、非侵襲的な血压推定、血中酸素飽和度の測定、鋭敏で個別化された心血管健康バイオマーカーの設計といった複数の臨床応用の性能を改善しうる。

方法

ベイズ的パルス逆畳み込みは、ノイズの濾波・拍タイミングの検出・脈波形状の抽出という3つの波形解析問題を同時に解くことを目指す。これは、波形の想定される起源を記述する解析的な生成モデルを規定することにより達成される（図6）。観測不能変数には、生物学的・物理的に妥当な値を表すベイズ事前密度が割り当てられる。最後に、観測信号データを条件として、観測されない変数にわたる同時ベイズ事後密度を更新することで推論が実行される。解析パイプラインは Snakemake [58] を用いて実装した。

血管波形の解析モデル

血管波形は、サンプル時刻 $t \in \mathbb{R}^N$ （必ずしも一様でない）における標本ベクトル $y \in \mathbb{R}^N$ として記述される。これらの標本は時間の連続関数 $y(t)$ の観測としてモデル化され、 $y_i = y(t_i)$ である。

観測可能な信号 $y(t)$ は、インパルス応答 $h(t)$ とインパルス列 $x(t)$ の畳み込みに残差項 $r(t)$ を加えたものとしてモデル化される。

$$y(t) = x(t) * h(t) + r(t) \dots (1)$$

これらの項はアルゴリズムの3つの目標に対応する。フィルタリングとは真の信号 $x * h$ を残差 r から分離することであり、拍タイミングは x に符号化され、脈波形状は h に符号化される。

残差は白色ノイズ $\varepsilon(t)$ と低周波ベースライン変動 $b(t)$ からなる。白色ノイズは、平均 $\mu_{\varepsilon}(t) = 0$ 、独立同分布の共分散関数 $k_{\varepsilon}(t, t') = \sigma_{\varepsilon}^2 \delta(t - t')$ をもつガウス過程としてモデル化される (δ は Dirac のデルタ関数)。低周波ベースライン変動は、重みベクトル $b \in \mathbb{R}^B$ と関数基底 $\beta(t)$ の内積としてモデル化される。

$$\beta(t) = [1, t, \sin(2\pi f_b t), \cos(2\pi f_b t), \sin(4\pi f_b t), \cos(4\pi f_b t), \dots]^T$$

$$r(t) = \varepsilon(t) + b(t) \dots (2) \quad \varepsilon(t) \sim \text{GP}(0, \sigma_{\varepsilon}^2 \delta(t - t')) \dots (3) \quad b(t) = b^T \beta(t) \dots (4)$$

インパルス列 $x(t)$ は、脈波の立ち上がり時刻 $z \in \mathbb{R}^M$ における M 個の Dirac デルタ関数の和である。

$$x(t) = \sum_{i=1}^M \delta(t - z_i) \dots (5)$$

当初、脈波数が既知でないとき、 M は脈波時刻 z が最初の観測サンプル時刻より前に始まり ($z_1 < t_1$)、最後の観測サンプル時刻より後に終わる ($z_M > t_N$) よう十分大きく初期化される。(後に脈波数が既知となったとき、 M を減らして観測窓外の不要な脈波を削除できる。)

インパルス応答 $h(t)$ は単一の脈波の形状を表す。これはフーリエ基底要素 $\phi(t) = [\sin(2\pi f_h t), \cos(2\pi f_h t), \sin(4\pi f_h t), \cos(4\pi f_h t), \dots]^T$ を重み $w \in \mathbb{R}^K$ で結合したものから構成される。フーリエ成分は周期的だが脈波形状は有限であるため、時間的に有界な窓関数 $\gamma(t)$ を適用する。脈波の振幅は定数のスケール因子 a により決定される。

$$h(t) = a \cdot \gamma(t) \cdot (w^T \phi(t) + 1) \dots (6)$$

窓関数は2つのシグモイド関数の積であり、脈波形状に左右の時間境界を与える。

$$\gamma(t) = 1 / (1 + e^{-(g_1(t - g_2))}) \cdot 1 / (1 + e^{-(g_3(t - g_4))}) \dots (7)$$

ベイズ的な拍タイミング事前分布

ベクトル z に対する事前分布は、拍タイミングに関する領域知識を符号化する。この事前分布は2つの望ましい性質を満たさなければならない。

- 性質1 (時間シフト不変性)：事前分布は時間シフト不変であるべきである。すなわち、観測信号の開始に対する絶対時刻についての仮定を置くことなく、心拍間の相対時刻に関する領域知識を符号化すべきである。
- 性質2 (曖昧性・冗長性の回避)：事前分布は、脈波時刻の巡回置換によってのみ異なる z の値の間の曖昧性や冗長性を避けるべきである。

時間シフト不変性 (性質1) に対処するため、事前分布を相対的な拍間間隔の観点で定義する。連続する脈波間の時刻を符号化する脈波間隔ベクトル $z' \in \mathbb{R}^{(M-1)}$ を定義する。

$$z'_i = z_{i+1} - z_i \dots (8)$$

周期性に起因する冗長性 (性質2) に対処するため、中央の脈波 z_m ($m = M/2$) が観測信号の中央の時刻 t_0 の後に生じる最初の脈波である、と恣意的に主張する。すなわち $z_{m-1} < t_0 < z_m$ である。式8 と組み合わせると、この主張は z_m の位置を $t_0 < z_m < t_0 + z'_{m-1}$ の範囲に制約する。時間シフト不変性を保つため、 z_m はこの範囲上で一様な事前密度をもつ。

$$z_m \sim \text{Uniform}(t_0, t_0 + z'_{m-1}) \dots (9)$$

z_m をサンプリングした後、他のすべての脈波時刻 $z_1, \dots, z_{m-1}, z_{m+1}, \dots, z_M$ は脈波間隔 z' によって完全に決定される。 z' から z への写像は行列 D_m で符号化されるアフィン変換である。

$$z = z' D_m + z_m \dots (10)$$

与えられた観測信号内では、基礎となる平均心拍数 f_{hr} が一定であり、ガンマ分布から引かれると仮定する。

$$f_{hr} \sim \Gamma(\alpha_{hr}, \lambda_{hr}) \cdots (11)$$

ガンマ分布の形状パラメータ α_{hr} と率パラメータ λ_{hr} は、確率密度の 99.999% が生理学的に現実的な 30 bpm から 150 bpm の範囲に入るよう選択した。

したがって期待される脈波間隔は $E[z'_i] = 1/f_{hr}$ である。心拍数 f_{hr} を用いて脈波間隔 z' を、期待脈波間隔の百分率を表す心拍数正規化形式 $z'' \in \mathbb{R}^{(M-1)}$ に変換する。

$$z' = z'' / f_{hr} \cdots (12)$$

正規化脈波間隔 z'' はガンマ分布からの独立同分布標本と仮定する。

$$z'' \sim \Gamma(\alpha_{z''}, \lambda_{z''}) \cdots (13)$$

脈波間隔パラメータ $\alpha_{z''}$ と $\lambda_{z''}$ を当てはめるため、ECG の R-R 間隔を疑似正解値として扱う。これらのパラメータは、Aurora-BP データセット [53] における 253 名からの 7,019 件の ECG 記録の心拍数正規化 R-R 間隔に対する最尤推定によって当てはめた。 $E[z''] = 1$ を保証するため、 $\lambda_{z''} = 1/\alpha_{z''}$ という制約を適用した。

ベイズ的な脈波形状事前分布

重み w に対する事前分布は、脈波形状に関する領域知識を符号化する。重みは多変量ガウスと仮定する。

$$w \sim N(\mu_w, \Sigma_w) \cdots (14)$$

形状分布のパラメータ μ_w と Σ_w はデータ駆動的に割り当てた。脈波形状事前分布は、Aurora-BP データセット [53] における 253 名からの 978 件の手首装着トノメトリ波形に当てはめた。光電容積脈波信号より高い周波数帯域幅をもつため、トノメトリ信号を選択した。波形からの平均セグメント脈波形状を用いて、式6による最尤推定で窓関数パラメータ (g_1, g_2, g_3, g_4) と 978 個の重みベクトル w を当てはめた。次に、データ由来の重みベクトル w に対する最尤推定でパラメータ μ_w と Σ_w を当てはめた。

※ 脈波セグメンテーションは血管波形から脈波形状を抽出する正解法ではないため、データ駆動型事前分布のバイアスを緩和する措置を講じた。

- フィルタ歪みを緩和するため、波形は濾波しなかった。代わりにデータセット作成者が付与した信号品質スコアが最高の波形のみを選択した [53]。
- 不正確な拍タイミング推定に起因する誤差を緩和するため、時刻同期した ECG の R-R 間隔を疑似正解の拍時刻として用いた。
- 重なり合う脈波による脈波の切断を緩和するため、拍間間隔が長い記録（心拍数 55 bpm 未満）のみを選択した。

ベイズ推論

ベイズ推論アルゴリズムは、JAX ハードウェア高速化ライブラリ [61] の上に構築された NumPyro 確率的プログラミングパッケージ [59, 60] を用いて実装した。学習率スケジューリングには optax ライブラリ [62] を用いた。

最大事後確率 (MAP) 解は、Dirac デルタ型の近似事後分布をもつ確率的変分推論を用いて推定した。サンプリングと勾配ベース最適化の効率を改善するため再パラメータ化トリック [63] を用いた。スケール因子 a 、オフセット重み b 、白色ガウスノイズ分散 σ_ε はいずれも制約なしパラメータとし、推論中に自由に変動させた。

事後分布は、脈波の欠落または過剰に対応する複数のモードをもつ。脈波の総数 M が事前に未知であるため、まず推定脈波時刻 z が観測時点の前後に伸びるよう M を選択する。最高事後確率のモードへ効率的に収束させるため、複数の状態で MAP 推定を初期化し、最高の事後密度をもつモードのみを保持する。初期状態は事前分布からサンプリングし、心拍数 f_{hr} は信号のパワースペクトルによってヒューリスティックにバイアスを与える。モー

ドを特定した後、観測時間範囲外の脈波を削除するため脈波数 M を減らす。

不確実性の定量化

不確実性の定量化のため、まずベイズ的パルス逆畳み込みを用いて実際の光電容積脈波波形に解析波形を当てはめた。例示のため、この解析解を用いて異なるサンプリングレートと信号対雑音比をもつ4本の3秒間ノイズ波形をシミュレートした。モデルの不確実性を定量化するため、マルコフ連鎖モンテカルロの No-U-Turn サンプリング [64] を用いて 10,000 の事後標本を抽出した。

評価指標

フィルタ精度の評価では、フィルタ前誤差（観測信号 - 真の信号）とフィルタ後誤差（濾波信号 - 真の信号）を比較し、フィルタ前後のデシベルパワー減衰を算出した。従来の無限インパルス応答フィルタの端部効果に起因する誤差を緩和するため、信号パワーを信号長にわたる Hann 関数で重み付けした。相対的な波形輪郭の変化のみに起因する誤差を分離するため、すべての信号を単位平均・単位分散にスケールした。

拍タイミング精度の評価では、まず推定脈波時刻を対応する真の脈波時刻と照合し、偽陽性と偽陰性を破棄した。各波形内で、推定脈波間隔と真の脈波間隔の二乗平均平方根誤差を算出した。

脈波形状抽出の評価では、真の脈波形状の総面積の関数として抽出脈波形状の誤差を定量化する指標を開発した。この指標を算出するため、まず真の脈波形状と予測脈波形状の間の Pearson 相関を最大化する時間シフトでアルゴリズムを整列させた。異なる長さの脈波形状を標準化するためゼロ埋めを用いた。次に両信号を単位面積（積分が1）となるようスケールした。誤差指標は、真の脈波形状と予測脈波形状の差の符号なし総面積として定義した。

ヒト記録における評価

生の光電容積脈波波形と時刻同期した ECG 信号を含む Aurora-BP データセット [53] を用いてベイズ的パルス逆畳み込みを評価した。不規則な体動アーチファクトは本研究の範囲外であるため、評価はデータセット著者が付与したヒューリスティックな光学信号品質指標が高い参加者に限って実施した。ECG の R-R 間隔を用いてゴールドスタンダードの脈波間隔を測定し、予測脈波時刻との一致を二乗平均平方根誤差で定量化した。

統計解析

すべてのアルゴリズムは、両側対立仮説による Wilcoxon 符号順位検定を用いて対比較した。多重検定を考慮し、各図内のすべての p 値に Bonferroni 補正を適用した。統計学的に有意な差のすべてが注釈されているわけではない。

データ・コードの利用可能性

本研究のために生成したシミュレーション波形のデータセットは著者への請求により利用可能である。Aurora-BP データセットは著者への請求により利用可能で、情報は <https://github.com/microsoft/aurorabp-sample-data> にある。

ベイズ的パルス逆畳み込みの実装、シミュレーション血管波形の生成、解析の実行、本研究の図の生成に用いたコードは <https://doi.org/10.5281/zenodo.18586098> で利用可能である。

図の説明

図1 | シミュレーションにおける信号フィルタリング精度 — (a) 典型的な 2 次 0.5-12 Hz Butterworth バンドパスフィルタは、生理学的周波数範囲においてノイズを不完全にしか減衰させず、位相歪みを導入する。ベイズ的パルス逆畳み込み (PD) はすべての周波数にわたってより大きなノイズ減衰を達成する。網掛け領域は 100 回のシミュレーションにわたる ± 1 標準偏差を表す。(b) ベイズ的パルス逆畳み込みは、典型的フィルタよりフィルタ歪みが少なく

波形を復元する。(c) 100 本のシミュレーション波形にわたって、ベイズ的パルス逆畳み込みが最良のノイズ減衰を達成する。各点は1本のシミュレーション波形を表す。ベースラインは Butterworth、Chebyshev、Neurokit2、PyPPG（表1 に定義）。縦軸 40 dB~0 dB、ベイズ PD は -31 dB。

図2 | シミュレーションにおけるタイミング検出精度 — (a) 典型的な拍タイミング特徴は、事前濾波した信号上のヒューリスティックな位置（局所最大の収縮期ピーク SP、局所最小の立ち上がり点 ON、1 次微分ピーク U、2 次微分ピーク A）から抽出される。(b) ベイズ的パルス逆畳み込み（PD）は心拍周期全体にタイミングを整列させる。(c) 100 本のシミュレーション波形にわたって、ベイズ的パルス逆畳み込みが最良の RMSE (4.9 ms) を達成する。「Ideal Filter」ベースラインは、シミュレーションの真のノイズなし波形から 1 次微分ピーク (U) を取ったもの。このベースラインでもベイズ PD より RMSE 中央値が高い ($p = 1e-5$)。

図3 | シミュレーションにおける形状抽出精度 — (a) 典型的には、脈波形状はヒューリスティックなタイミングマーカーに基づき濾波信号を整列・平均化することで抽出され、脈波間の重なりは無視される。(b) ベイズ的パルス逆畳み込み（PD）は脈波形状の重なりを明示的にモデル化する。(c) 100 本のシミュレーション波形にわたって、ベイズ的パルス逆畳み込みが最低の脈波形状面積百分率誤差 (6.9%) を達成する。「Ideal Filter」ベースラインは、シミュレーションの真の脈波時刻を用いて真のノイズなし信号から得た平均脈波形状。

図4 | ヒト記録における拍タイミング評価 — (a) 48 歳仰臥位参加者の実験記録の拍タイミング解析。心電図 (ECG) のピークが、典型的な PyPPG (U) アルゴリズムとベイズ的パルス逆畳み込み（PD）から抽出した脈波間隔の精度を評価するための代理正解値である。(b) 上記波形から抽出した脈波間隔。灰色の破線はサンプル周期 $1/f_s$ の整数倍を表す。(c) 105 件のヒト記録にわたって、ベイズ的パルス逆畳み込みは ECG に対してより低い RMSE 中央値 (5.1 ms 対 8.3 ms、 $p = 1e-10$) をもつ。各点は1本の血管波形を表す。値は対数スケール。

図5 | 不確実性の定量化 — 真の信号は 5 秒間の光電容積脈波波形から導出（最初の 3 秒のみ描画）。ノイズ信号は異なるサンプリングレート (f_s) と信号対雑音比 (SNR) でシミュレート。赤で示すのは最大事後確率 (MAP) 推定と、10,000 の MCMC 標本から算出した事後の 99% 信用区間。脈波時刻の周辺事後分布は MCMC 事後標本からのカーネル密度推定として示す。(a) 高 $f_s = 64$ Hz、高 SNR = 10。(b) 低 $f_s = 16$ Hz、高 SNR = 10。(c) 高 $f_s = 64$ Hz、低 SNR = 1。(d) 低 $f_s = 16$ Hz、低 SNR = 1。

図6 | 血管波形の解析モデル — (a) 観測信号 $y(t)$ のタイミング・形状・ノイズ成分を記述する生成方程式。(b) ベイズ的グラフィカルネットワーク表現。矢印は変数間の条件付き依存を表す。(c) 生成モデル内の主要変数の図示。

表1 | ベースラインアルゴリズム

課題	名称	説明
信号フィルタリング	Butterworth	2 次 0.5~12 Hz Butterworth バンドパスフィルタ [22, 36]
	Chebyshev	4 次 0.5~12 Hz Chebyshev バンドパスフィルタ、阻止帯域減衰 20 dB 以上 [22, 27]
	NeuroKit2	NeuroKit2 Python ライブラリの既定 PPG フィルタ [21]
	PyPPG	PyPPG Python ライブラリの既定 PPG フィルタ [22]
タイミング検出	PyPPG	PyPPG 既定フィルタ + PyPPG の SP/ON/U/A 検出器
	Ideal Filter	シミュレーションの真のノイズなし信号に適用した PyPPG の 1 次微分ピーク (U) 検出器
形状抽出	NeuroKit2	NeuroKit2 既定フィルタと SP 検出器 + 脈波セグメンテーションと平均化

課題	名称	説明
	PyPPG	PyPPG 既定フィルタとタイミング法 + 脈波セグメンテーションと平均化
	Ideal Filter	真の脈波時刻を用いて真のノイズなし信号に直接実行したセグメンテーションと平均化

訳注（読解上の要点 — 本プロジェクトへの含意）

1. 本手法は前進波と反射波に分解していない。脈波形状 $h(t)$ はフーリエ基底+シグモイド窓による不可知論的な表現であり、 τ （反射波帰還時刻）も Γ （反射係数）も推定しない。したがって PDA（脈波分解解析）の競合ではなく、その前段（フィルタリング・拍検出・形状抽出）を置き換えるものと位置づけるのが正確である。
2. ※ 最も重要な所見は「Ideal Filter」の結果である。真のノイズなし信号と真の拍時刻を与えても、従来のセグメンテーション+平均化による形状抽出誤差は改善しなかった（48~49% のまま）。すなわち形状抽出誤差の主因は、フィルタでも拍検出でもなく「1拍を切り出す」操作に内在する脈波の重なりと切断である。これは wrap-around 問題を定量化した引用可能な証拠である。
3. 実データでの検証は拍間隔（タイミング）のみである。フィルタリング 90% 減、形状抽出 85% 減はいずれもシミュレーションのみの結果であり、著者も「今後の研究ではフィルタリングと形状抽出の機能を活用する下流応用で評価すべき」と明記している。
4. 実装は NumPyro / JAX であり全体が微分可能。MAP は Dirac デルタ近似事後分布による確率的変分推論、不確実性は MCMC (NUTS) 10,000 標本。多点初期化で多峰性に対処している点は、非線形最小二乗の初期値依存性への対策と同じ発想である。コードは Zenodo で公開 (DOI 10.5281/zenodo.18586098)。
5. 不確実性の定量化は事後分布の幅であり、CRLB やプロファイル尤度による識別性の解析ではない。サンプリングレートと SNR への応答を示すにとどまる。
6. Aurora-BP データセット（生の未濾波血管波形+精密に時刻同期した ECG、253 名）は、モニタ加工済み波形の問題を回避しうる資源として注目に値する。事前分布はトノメトリから、評価は重複しない被験者の PPG から取っており、設計は誠実である。
7. 著者が明記する限界：①多峰性が信号長・脈波数に対して組合せ的に増大 ②脈波形状を静的と仮定（周術期の急性変化には未対応）③推論速度がリアルタイムに満たない。
8. 形状事前分布の当てはめに 心拍数 55 bpm 未満の記録のみを用いている（重なりを避けるため）。高心拍では事前分布が代表的でない可能性がある。
9. 査読前のプレプリント (bioRxiv、2026年2月11日投稿、CC-BY 4.0) である。引用の際はその旨を明記すべきである。