

【本PDFについて】 本文書は下記原著論文の日本語逐語訳です(本文・図・表)。原論文は Scientific Reports 誌のオープンアクセス論文であり、Creative Commons Attribution 4.0 International License(CC BY 4.0)の下で、出典を明記した上での翻訳・複製・再配布が許諾されています(ライセンス表記は論文末尾参照)。

原著: Shin H, Noh G, Choi B-M. Photoplethysmogram based vascular aging assessment using the deep convolutional neural network. *Scientific Reports* (2022) 12:11377. <https://doi.org/10.1038/s41598-022-15240-4>

ライセンス: CC BY 4.0 (<http://creativecommons.org/licenses/by/4.0/>) / **翻訳:** Claude Code による機械翻訳(逐語訳)。翻訳は原文の改変(翻案)に該当します。正確な内容は必ず原文を参照してください。参考文献リストは原文のまま(翻訳対象外)のため省略し、本文中の上付き引用番号は原文の参考文献番号を指します。

www.nature.com/scientificreports — OPEN(オープンアクセス)

深層畳み込みニューラルネットワークを用いた光電容積脈波に基づく血管老化評価

Photoplethysmogram based vascular aging assessment using the deep convolutional neural network

Hangsik Shin^{1✉}, Gyujeong Noh^{2,3} & Byung-Moon Choi^{2✉}

¹ Department of Convergence Medicine, Asan Medical Center, University of Ulsan College of Medicine, Seoul, Republic of Korea(蔚山大学校医科大学峨山医療センター融合医学教室、韓国ソウル)。² Department of Anesthesiology and Pain Medicine, Asan Medical Center, University of Ulsan College of Medicine, Seoul, Republic of Korea(同 麻酔科・疼痛医学教室)。³ Department of Clinical Pharmacology and Therapeutics, Asan Medical Center, University of Ulsan College of Medicine, Seoul, Republic of Korea(同 臨床薬理学・治療学教室)。[✉] email: hangsik.shin@gmail.com; byungmoonchoi7@gmail.com

要旨 Abstract

血管老化による動脈スティフネス(動脈硬化度)は、心血管リスクの評価における主要な指標である。本研究では、血管年齢の非侵襲的評価のために、光電容積脈波(PPG)に深層学習を適用することによる年齢推定法を提案する。提案する深層学習ベースの年齢推定モデルは、3つの畳み込み層と2つの全結合層から構成され、PPG波形特性の血管年齢推定への寄与を説明するために、Grad-Camを備えた説明可能な人工知能モデルとして開発された。深層学習モデルは、20~89歳の合計752名の成人からの、脈波ごとにセグメント化されたPPGを用いて開発され、性能は、実年齢と推定年齢との間の平均絶対誤差、二乗平均平方根誤差、Pearson相関係数、および決定係数を用いて定量的に評価された。その結果、平均絶対誤差8.1歳、二乗平均平方根誤差10.0歳、相関係数0.61、および決定係数0.37が得られた。入力信号が結果に寄与する重みを決定するために使用されるGrad-Camが、PPGセグメントの年齢推定への寄与を検証するために採用され、その寄与は収縮期ピーク周辺で高かった。本研究の結果は、畳み込みニューラルネットワークに基づく説明可能な人工知能モデルが、追加の特徴点検出プロセスなしに既存モデルを上回ることを示唆している。さらに、それはPPGに基づく血管老化評価の根拠を提供しうる。

Thomas Sydenhamは、「人は血管とともに老いる(A man is as old as his arteries)」と述べた。加齢に伴い、動脈および細動脈の壁は肥厚し、動脈内の空間はわずかに拡大し、動脈および細動脈の壁の弾性組織は減少する。加えて、これらの変化は血管をより硬く、弾性の低いものにする。したがって、動脈スティフネスは血管老化とともに増加す

る¹。動脈スティフネスは、心血管リスク²⁻⁶の、そして顕性の心血管疾患のない無症候性個人^{7,8}の強力な指標である。加えて、動脈スティフネスの増加は、高血圧、糖尿病、脂質異常症、腎疾患、喫煙といった冠動脈疾患のリスクと関連している⁹。心血管(CV)リスクのスクリーニングと管理は、心血管疾患(CVD)に伴う死亡率、罹患率、および社会経済的負担を軽減するために重要である。脈波伝播速度(PWV)は、血管老化の評価の臨床的ゴールドスタンダードとみなされている。専門家は、PWVを、動脈スティフネスを評価するための単純、非侵襲的、頑健、かつ再現可能な方法とみなしている¹⁰。PWVの正常値および参照値は、欧州8か国にわたる13の異なるセンターからの16,867名の個人および患者から収集されたデータを用いて、Reference Value for Arterial Stiffness Collaboration から得られた¹¹。PWVは様々な方法で測定できる。その中でも、動脈樹に沿った脈波の伝達速度である頸動脈-大腿動脈間PWV(cfPWV)は、動脈スティフネスを記述する最良の指標とみなされている^{4,10-13}。cfPWVは通常、右総頸動脈および右大腿動脈における波形から得られ、2つの拍動波形の脈波立ち上がり間の時間遅延が測定される。しかしながら、cfPWVは計算方法によって異なりうる。cfPWVは異なる距離——直接の頸動脈-大腿動脈間距離、または減算距離(胸骨から大腿動脈まで-頸動脈から胸骨まで)のいずれか——を用いて決定されうるからである。その結果、cfPWVは計算方法によって最大30%変動する可能性があり、この差は臨床的に有意である^{14,15}。

このように、PWVの計算のためには、人体の様々な部位からの信号の多部位測定が必要となる。指や手首のみならず、足首、大腿、または頸部にも信号記録に使用される機器を装着するのは煩雑であるため、これは日常生活への適用が困難である。加えて、異なる距離計算方法による偏差を考慮する必要がある。この限界を改善するために、単一の身体部位で測定された光電容積脈波(PPG)波形の形状変化を解析することによって血管老化を評価する技術が提案された¹⁶⁻²¹。PPG波形は、パルス型の圧がチューブ(血管)に加えられたときに生じる入射波-反射波関係による流体流変化としてモデル化できるため^{22,23}、チューブのコンプライアンス、拡張性(distensibility)、スティフネスなどの物理特性がPPG波形に反映されうる。これらの特性に基づき、PPGの原波形または微分波形と主要な特徴点を用いた血管スティフネスの評価が試みられてきた²⁴⁻²⁶。Takazawaは、PPGの二次微分特徴に基づく加齢関連指標を導出し、年齢との相関0.8を示した²⁵。高血圧患者を対象とした別の研究では、二次微分PPG(SDPPG)加齢指数は有望な指標と考えられたが、PWVと比較すると、加齢評価の有用性はより低かった²⁴。Millasseauは、血管老化によるPPG波形の変化に基づいてPWVを推定するためのスティフネス指数(SI)と反射指数(RI)を開発し、SIがPWVと相関係数0.65を持ち、年齢と強い相関($R = 0.63$)を持つことを示した¹⁶。加えて、PPG波形または特徴点を用いて加齢を評価するために、PPGおよび二次微分PPGの特徴を用いる指数が開発され、年齢との相関係数0.56が得られた²⁶。他の研究は、PPGが入射波成分と反射波成分の組み合わせで構成されるという事実に焦点を当てており、複数のガウス分布²⁰またはLevenberg-Marquardt最適化アルゴリズム(LMO)¹⁸を用いて再構成されたPPGの特性を通じて、PPGと年齢との相関を見出す研究が含まれる。最近の関連研究では、スマートフォンカメラを用いてPPGが取得され、機械学習および深層学習技術を適用することによって年齢が推定され²¹、0.28~0.43の範囲の R^2 と10.8~12.3の範囲のRMSEが得られた。上記の研究と同様に、単一のPPGを用いて血管老化を推定する様々な方法が提案されてきたが、被験者数の不足($N < 10$)¹⁸や、被験者および測定環境情報の欠如²¹のために、信頼性のある方法に関する継続的な研究が依然として必要とされている。既存の方法の中で、いくつかの研究がSDPPGの有用性について報告しており、その再現性が評価されている²⁴⁻²⁶。しかしながら、SDPPG加齢指数を導くために必要な二次微分PPGのピーク検出は誤りに対して脆弱であり、被験者の特性によっては二次微分特徴点が観察されない場合もあるため、典型的な環境における日常活動での利用は困難である^{17,27,28}。これまでの研究結果は、PPGが血管老化の評価のための有用な情報含有信号であることを示唆してきた^{16-18,21,24-26,29-32}。現在、PPGベースの血管老化評価研究のほとんどは、PPGの特徴を抽出し、回帰モデルを用いて年齢を推定することによって実施されている^{16,18,21,24-26,29}。検出された特徴を用いて血管老化を評価する研究は、精緻化された特徴によって安定した性能

を示してきた。しかしながら、それらには、特徴の検出および誤検出の補正のコストが非常に高いという限界がある。したがって、PPG原波形に深層学習を適用する方法が最近提案されている^{21,30–32}。

本研究は、経験的かつ手動の特徴点検出プロセスなしに、深層学習ベースのアプローチを採用することによって自動的に最適化された特徴を検出し、PPGを用いて血管老化を評価すること、および開発された血管老化評価モデルの性能を評価することを目的とする。特に、本研究は、入力PPG信号が加齢推定にどのように寄与するかを検証するために、説明可能な人工知能(XAI)としてGrad-Camを使用する。深層学習ベースのアプローチは、既存の特徴ベースのアプローチとは異なり、モデルが最適な特徴を自動的に選択するという点で異なるため、まだ発見されていない特徴を用いることによって推定性能が改善される可能性がある³³。加えて、XAIの適用を通じて、血管老化の評価における主要な波形特徴を追跡することが可能である。したがって、PPGを用いた血管老化の評価において、深層学習、特にXAIを用いるアプローチは、血管老化の指標としての重要なPPG特性への洞察を提供するとともに、血管老化の評価性能を改善しうる。

方法 Methods

研究デザインと被験者 Study design and subjects

本研究は観察研究として設計された。研究プロトコルは、峨山医療センター(韓国ソウル)の施設内審査委員会によって承認され(承認番号: 2015–0104)、モニタリングされた。また、実験参加に先立ち、各被験者から研究への参加に対するインフォームド・コンセントが取得された。研究全体は、関連するガイドラインおよび規制に従って実施された。われわれは、2015年7月から9月の間に峨山医療センターにおいて待機手術(甲状腺、乳腺、または腹部)が予定されており、米国麻酔科学会(American Society of Anesthesiologists)の全身状態分類が1、2、または3である、20–89歳の患者を登録した。除外基準は以下のとおりであった: 妊娠中または授乳中の女性、心血管・肝・腎機能の臨床的に有意な障害、心不整脈の既往、自律神経機能に影響しうる薬剤の使用、術前の鎮痛薬または神経遮断薬の使用、および薬物乱用または精神疾患の既往。すべての患者は、手術当日の午前0時から絶食することが求められ、前投薬は行われなかった。患者は、23~25℃の周囲温度の静かな手術室において、仰臥位で少なくとも5分間の環境順応が許された。鼻の光電容積脈波を取得するために、特別に設計されたセンサが鼻柱と鼻中隔の間に装着された。光電容積脈波データは、E2-KITパルスオキシメトリ機器(KTMED, Co. Ltd., 韓国ソウル)を用いて、125または250 Hzのサンプリング周波数で3分間収集された。

データセット Dataset

光電容積脈波データは、合計1,000名の参加者から取得された。機器の動作エラーにより信号喪失が生じた17名の参加者のデータ、および体動アーチファクトのために区間の50%超が明瞭でなかった231名の参加者のデータを除外し、752名の参加者のデータが解析に使用された。解析に含まれた患者の特性をTable 1にまとめる。

Table 1(表1) 解析に含まれた患者の特性(N = 752)

特性	値
男性/女性	331 (44.0)/421 (56.0)
ASA PS 1/2/3	465 (61.8)/ 253 (33.6)/ 35 (4.6)
体重 (kg)	60.1 (53.1–68.2)
身長 (cm)	161.1 (155.8–167.2)
BMI (kg/m ²)	23.1 (20.9–25.7)
年齢 (歳)	56 (46–65)
19–29	11 (1.3)
30–39	59 (7.9)
40–49	165 (21.9)
50–59	214 (28.5)
60–69	178 (23.7)
70–79	108 (14.4)
80–89	17 (2.3)
社会的特性(Social characteristics)	
喫煙	109 (14.5)
飲酒	217 (28.9)
既往歴(複数回答可)(Medical history (multiple answers possible))	
高血圧	205 (27.3)
糖尿病	71 (9.4)
肺疾患	17 (2.3)
腎疾患	6 (0.8)
肝疾患	24 (3.2)
神経疾患	5 (0.7)
その他	3 (0.4)

(表1脚注)データは、適宜、件数(パーセント)または中央値(25–75パーセンタイル)として提示される。ASA PS: 米国麻酔科学会全身状態分類(1: 正常健康患者、2: 軽度の全身性疾患を持つ患者、3: 重度の全身性疾患を持つ患者)、BMI: 体格指数。肺疾患: 喘息(10)、肺気腫(2)、気管支拡張症(1)、慢性閉塞性肺疾患(3)、陳旧性結核(1)。腎疾患: 慢性腎臓病(2)、末期腎不全(4)。肝疾患: B型肝炎ウイルス(12)、C型肝炎ウイルス(4)、肝硬変(8)。神経疾患: 脳卒中(1)、脳血管障害(3)。その他: 狭心症(1)、頸動脈狭窄(1)、骨髄異形成症候群(1)。

Figure 1(図1) PPGセグメントと特徴点。

図中ラベル訳: Systolic Peak=収縮期ピーク / Diastolic Peak=拡張期ピーク / Pulse_{onset}=脈波立ち上がり点

データ前処理 Data preprocessing

本研究では、代表PPG拍動波形が生成され、血管老化の同定に利用された。代表PPG拍動波形の生成プロセスは以下のとおりである: まず、有限インパルス応答(FIR)バンドパスフィルタを用いて、呼吸または高周波ノイズの影響が除去された。FIRフィルタは、0.5–10 Hzの通過帯域を持ち、サンプリング周波数に応じて125または250に等しいタップ数を持つように設計された。続いて、信号を平滑化するために、50 msウィンドウ長の移動平均フィルタが適用された。次に、個々のPPG脈波を得るために、脈波間で最小値を持つ変曲点である脈波立ち上がり(Pulse_{onset})に基づいて、PPGがセグメント化された。Figure 1に、PPGセグメントとその代表的な特徴を示す。脈波立ち上がりの検出には、適応閾値ピーク検出法³⁴が使用された。PPGの自動セグメンテーションの場合、誤った脈波立ち上がり検出によりセグメンテーションエラーが生じる。したがって、セグメンテーションエラーを最小化するために、脈波間間隔(pulse-to-pulse interval: PPI)に基づいて正常範囲内のセグメントが選択された。正常セグメントの同定には、脈波立ち上がりに基づく脈波間間隔が使用された。このプロセスでは、まず脈波セグメンテーションが実施され、PPIの外れ値を

除外して、PPIの正常範囲に対応するセグメントのみが選択された。PPI外れ値は、1.5四分位範囲(IQR)基準を適用することにより、 $Q1 - 1.5 \times QD$ より小さい値、または $Q3 + 1.5 \times QD$ より大きい値として定義された。Q1: 第1四分位数、Q3: 第3四分位数、QD: 四分位偏差。続いて、セグメント長が外れ値判定基準に該当しないセグメントのみを用いて、代表PPG脈波が得られた。次いで、各サンプル位置におけるPPGセグメントの中央値を取ることによって、代表PPG脈波が得られた。このとき、各PPGセグメントの長さは異なりうるため、各セグメントはPPIの中央値の長さを持つように補間され、セグメント補間には3次スプライン補間が使用された。最後に、中央値から得られた波形に50 ms ウィンドウ長の移動平均フィルタを適用することによって、代表波形が生成された。Figure 2は、このデータ処理プロセスを記述している。深層学習モデルの入力のために、代表波形は0から1の間へスケールリングすることによって正規化され、その後、入力ベクトルのサイズ(144サンプル)に従ってリサイズされた。このとき、リサイズはMatlab 2020b関数(The MathWorks, Inc., 米国マサチューセッツ州)を用いて実施され、リサンプリングと正規化は0-1の範囲の値で実施された。

Figure 2(図2) 代表光電容積脈波脈波を導出するためのデータ前処理手順。バンドパスフィルタは、0.5-10 Hzの通過帯域を持つ有限インパルス応答フィルタである。信号の平滑化は、50 msウィンドウ長の移動平均フィルタを用いて実施された。IQR: 四分位範囲。

図中ラベル訳: Bandpass Filtering=バンドパスフィルタリング / Smoothing=平滑化 / Pulse-by-pulse Segmentation=脈波ごとのセグメンテーション / Outlier segment removal=外れ値セグメント除去 / Median waveform=中央値波形 / Calculation of quantile values and IQR of segment length=セグメント長の分位値およびIQRの計算 / Outlier segment removal with $< Q1 - 1.5 \cdot IQR$ or $> Q3 + 1.5 \cdot IQR = Q1 - 1.5 \cdot IQR$ 未満または $Q3 + 1.5 \cdot IQR$ 超の外れ値セグメント除去

Table 2(表2) 最良性能モデルのために選択されたハイパーパラメータ。ベイズ最適化からの最適値は太字で示す。

ハイパーパラメータ	比較された選択肢(テスト)
畳み込み層数	2 3 4 5 6
全結合層数	1 2
全結合層のノード数	512 1,024 2,048
ドロップアウト率	0 0.1 0.2 0.3 0.4 0.5
学習率	0.001 0.0001
活性化関数	ReLU
オプティマイザ	ADAM

深層学習モデル Deep learning model

本研究で採用された畳み込みニューラルネットワーク(CNN)の構造は、CNNと全結合ネットワークから構成されるよく知られたアーキテクチャであり、そのハイパーパラメータは、グリッドサーチ法³⁵を通じてヒューリスティックに選択された。Table 2は、最良の性能を持つモデルを選択するために、様々な構造またはハイパーパラメータを持つモデルが作成され評価されたことを示している。選択されたモデルはTable 2に太字で示されており、既存研究との比較評価のために訓練データセットを用いて検証された。これは、既存研究の性能が、別個のテストセットを使用せず、開発に使用されたデータで評価されていたことを考慮したものである。最良のCNNモデルは、2つの1次元畳み込み層と、出力ニューロンの前に1024ノードおよび0.2のドロップアウト率を持つ2つの全結合層から構成された。入力層は正規化されたPPGから構成された。PPG信号は144×1の行列から構成され、ここで「144」は時間サンプル数であり、「1」は単一チャネルのPPGを表す。畳み込み層は、特徴抽出を実行する畳み込み・非線形層から構成された。各畳み込み層には異なる数のフィルタが採用された。第1層、第2層および第3層には、それぞれ16および32のフィルタが採用され、それらのサイズは10および8、ストライドは1であった(訳注: 原文のまま。層数と数値の個数が一致しない)。非線形活性化

化関数として、正規化線形ユニット(ReLU)関数がすべての層で採用された。Figure 3に、開発されたモデルの構造を提示する。開発されたCNNは、損失関数として平均二乗誤差(MSE)を、最適化アルゴリズムとしてAdamオプティマイザを採用することにより、教師あり学習アプローチを用いて訓練された。Adamオプティマイザのパラメータは、移動平均勾配の指数減衰率(β_1)に0.9、二乗勾配の移動平均の指数減衰率(β_2)に0.999と設定された。最適化手続きはバッチサイズ50で実施され、その後の100イテレーション以内に検証精度がもはや改善しなくなるまで反復された。検証プロセスでは、10分割交差検証が使用された。このとき、訓練セットとテストセットは9:1の比で分割され、訓練セットの25%が検証セットとして使用された。その結果、各フォールドについて、合計752名の被験者のうち676名のデータが訓練セットとして、76名の被験者のデータがテストセットとして使用され、訓練セット内の507名の被験者のデータが訓練に、169名が検証に使用された。訓練、テスト、および検証セットの分割の過程では、各データセットについて年齢を均等に分布させるために、層化データサンプリングが適用された。提案CNNモデルは、2.8 GHz Intel Core i9-10900Fプロセッサ、128 GB 1,600 MHz DDR3 RAM、NVIDIA Geforce™ RTX 3090、およびPython 3.8: Anaconda、Tensorflow 2.5を用いて開発および検証された。

Figure 3(図3) 開発されたモデルの構造。入力層は、144×1行列の正規化された光電容積脈波から構成された。畳み込み層は、異なる数のフィルタを持つ畳み込み・非線形層から構成された。第1層、第2層および第3層には、それぞれ16および32のフィルタが採用され、それらのサイズは10および8、ストライドは1であった。続いて、出力ニューロンの前に、0.2のドロップアウト率を持つ1024ノードを用いて、2つの全結合層が接続された。PPG: 光電容積脈波、CONV: 畳み込み、FC: 全結合、ReLU: 正規化線形ユニット。

図中ラベル訳: 1 channel (144 x 1)=1チャンネル(144×1) / 16 channel=16チャンネル / 32 channel=32チャンネル / 1024 nodes (1 x 1)=1024ノード(1×1) / 1 node=1ノード / PPG waveform=PPG波形 / Input Layer=入力層 / CONV Layer1=畳み込み層1 / CONV Layer2=畳み込み層2 / FC Layer1 dropout (0.2)=全結合層1 ドロップアウト(0.2) / FC Layer2 dropout (0.2)=全結合層2 ドロップアウト(0.2) / Output Layer=出力層

統計的検証 Statistical validation

開発された深層学習モデルの年齢推定性能は、平均絶対誤差、二乗平均平方根誤差、Pearson相関係数、決定係数、およびBland-Altman解析を用いて定量的に評価された。統計解析は全データに対して実施され、高血圧、糖尿病、飲酒、および喫煙に応じた群間比較も実施された。群間の有意性を評価するために、正規性と等分散性を満たした各群については独立t検定が使用され、そうでない場合はMann-Whitney U検定が使用された。正規性の検定にはShapiro-Wilk検定が、等分散性の検定にはLevene検定が使用された。すべてのデータ処理手順および統計的検証プロセスは、Matlab 2020b(The MathWorks, Inc., 米国マサチューセッツ州)を用いて実施された。

Grad-CAM Grad-CAM

クラス活性化マップ(class activation map: CAM)は、CNNモデルの最終層に大域平均プーリング(global average pooling: GAP)を含めることによって、画像における分類結果に大きな影響を持つ主要な要素を決定する方法である³⁶。CAMは、ブラックボックスとみなされる深層学習モデルの内部の働きを説明でき、入力データのどの要素が分類にとって重要な情報であるかを教えることができるAIの一種である。しかしながら、CAMを適用するためには、モデルの最終層にGAP層を追加しなければならない、深層学習モデルを構築する際の制約となる。Grad-Camは、勾配によって特徴に接続される重みを計算する方法であり、それによって、元の深層学習モデル構造を変更することなくCAMを得ることを可能にする³⁷(補足資料を参照)。Grad-Camは既存のモデル構造をそのまま使用できるため、全結合層、構造化出力、またはマルチモーダル入力を含むものなど、ほとんどのCNNモデルに適用可能である。

倫理的承認 Ethical approval

研究プロトコルは、峨山医療センター(韓国ソウル)の施設内審査委員会によって承認され(承認番号: 2015-0104)、モニタリングされた。また、実験参加に先立ち、各被験者から研究への参加に対するインフォームド・コンセントが取得された。研究全体は、関連するガイドラインおよび規制に従って実施された。

結果 Results

加齢評価における開発モデルの性能 Performance of the developed model in aging assessment

Table 3に、開発モデルを用いた年齢推定のMAE、RMSE、範囲、相関係数、および決定係数を示す。結果の値は、交差検証のために各フォールドで得られたテストセットのすべての結果を集約することによって計算された。結果から、全テストデータセットの場合、開発モデルは、0.1–29.2歳の誤差範囲において、約8歳のMAEおよび10歳のRMSEを示し、相関係数は0.61、決定係数は0.37であった。Figure 4に、Bland–Altman解析の結果を示す。Bland–Altmanプロットでは、20–80歳の全範囲にわたってバイアスはおよそ0であることが見て取れ、推定値と実測値の偏差のほとんどは95%信頼区間内に位置している。ここで、95%信頼区間の上限は19.7であり、下限はおよそ–19.7であった。さらに、高血圧、糖尿病、飲酒、または喫煙に基づくモデル性能に有意差はなかった。

Table 3(表3) モデルの性能

データセット	N	MAE(歳)	RMSE(歳)	誤差範囲(歳)	R	R ²
血圧(Blood pressure)						
高血圧	205	8.2	10.0	0.1 – 29.2	0.6	0.35
非高血圧	547	8.2	10.0	0 – 29.1	0.62	0.38
血糖(Blood glucose)						
糖尿病	71	7.8	9.6	0.1 – 21.5	0.73	0.51
非糖尿病	681	8.2	10.1	0 – 29.2	0.59	0.35
飲酒(Drinking)						
飲酒あり	217	7.8	9.6	0 – 25.8	0.66	0.43
飲酒なし	535	8.4	10.2	0 – 29.2	0.59	0.35
喫煙(Smoking)						
喫煙あり	109	8.9	10.8	0 – 25.8	0.6	0.36
喫煙なし	643	8.1	9.9	0 – 29.2	0.61	0.38
合計	752	8.1	10.0	0 – 29.2	0.61	0.37

Figure 4(図4) 全被験者(N = 752)の推定年齢と実年齢との比較のためのプロット。(a) 散布図、および(b) Bland–Altmanプロット。R: Pearson相関係数、R²: 決定係数、SD: 標準偏差。

図中ラベル記: Total Patients (N=752)=全患者(N=752) / Regression curve (R=0.61, R²=0.37)=回帰曲線(R=0.61, R²=0.37) / Identical line=恒等線 / Real age (years)=実年齢(歳) / Estimated age (years)=推定年齢(歳) / Bias (0)=バイアス(0) / Limits of Agreements (±1.96 SD): –19.7 – +19.7=一致限界(±1.96 SD): –19.7~+19.7 / (Real age – estimated age) (years)=(実年齢–推定年齢)(歳) / (Real age + estimated age)/2 (years)=(実年齢+推定年齢)/2(歳)

Grad-CAM Grad-CAM(結果)

Figure 5に、各年齢群についてのPPG波形とGrad-Camの結果を示す。図において、赤色はより大きな重みを持つ区間を表し、青色はより小さな重みを持つ区間を示す。Grad-Camの結果は、収縮期ピーク近傍の波形が血管老化の評価において最も重要な役割を果たすことを示唆している。これらの傾向は、年齢群間で有意には異ならない。ただ

し、より詳細に観察すると、Pulse_{onset}直後の波形の重要度、および加齢評価にとって高い重要度を持つ全体領域(赤色)は、減少する。

Figure 5(図5) (a) 20歳代、(b) 30歳代、(c) 40歳代、(d) 50歳代、(e) 60歳代、(f) 70歳代、および(g) 80歳代の被験者の血管老化評価のための、光電容積脈波波形とGrad-Camの結果。垂直線は時間の中点を表す。加齢の進行に伴い、Pulse_{onset}近傍の重要度は減少し、下降相における中間レベルの重要度(黄色)の区間は増加する傾向がある。

図中ラベル記: Amplitude (a.u.)=振幅(任意単位) / Normalized time (n.u.)=正規化時間(正規化単位) / High=高 / Low=低

Table 4(表4) 様々な血管老化評価モデルについての相関係数、決定係数、および二乗平均平方根誤差(RMSE)の比較

入力タイプ	指標	N(年齢範囲)	相関係数	決定係数	RMSE(歳)
波形(Waveform)	提案手法(Proposed)	752 (19-87)	0.61	0.37	10.0
	Resnet ²¹	4,769 (18-79)	n.a	0.28	12.3
導出特徴量(Derived Feature)	スティフネス指数 ¹⁶	87 (21-68)	0.65	n.a	n.a
	スティフネス指数 ²⁹	124 (20-74)	0.63	n.a	n.a
	二次微分PPG加齢指数 ²⁴	248 (60歳未満)	-0.37(60歳未満)	n.a	n.a
		276 (60歳超)	-0.13(60歳超)	n.a	n.a
	PPGオーグメンテーション指数 ²⁴	248 (60歳未満)	0.21(60歳未満)	n.a	n.a
		276 (60歳超)	0.29(60歳超)	n.a	n.a
	二次微分PPG加齢指数 ²⁵	600 (30-89)	0.80	n.a	n.a
	二次微分PPG加齢指数 ²⁶	93 (36-86)	0.30	n.a	n.a
	リッジ回帰 ²¹	4,769 (18-79)	n.a	0.50	10.2
	回帰 ²¹	4,769 (18-79)	n.a	0.43	10.8
	分解波形特徴量 ¹⁸	4 (13-39)	-0.87-0.98	n.a	n.a
	人工ニューラルネットワーク ³¹	757 (19-87)	0.63	n.a	10.0
	XGBoost ³²	752 (19-87)	0.63	0.39	9.9

考察 Discussion

加齢評価のための開発モデルの性能 Performance of the developed model for aging assessment

Table 4に、本研究で開発されたモデルの相関係数、決定係数、およびRMSEを、先行研究の結果と比較して示す。本研究におけるR値は0.61であり、既存の特徴量ベースのSIおよびSDPPG研究からのR値0.63-0.66と同程度であった。加えて、開発されたモデルが、高血圧や糖尿病などの慢性疾患、あるいは飲酒や喫煙などの生活習慣にかかわらず、血管の年齢を推定できることが報告されている。本研究では、モデル最適化のために、畳み込み層の数、全結合層の数、およびドロップアウト率が調整され、モデルが開発されてその性能が評価された。使用されたすべてのモデルの相関係数の平均(範囲)は 0.59 ± 0.01 (0.55-0.61)であり、平均MAE(範囲)は 8.4 ± 0.1 歳(8.2-8.6)であって、モデル間にわずかな性能偏差があることが確認された。しかしながら、MAE推定結果は、モデルの種類による性能の差が1歳未満であることを示しており、いずれか一つのモデルを適用しても年齢推定結果に有意な影響はないことを示唆している。研究で評価された様々なモデルの性能をTable 5に示す。加えて、モデルを意図的に過学習させることによって、データ拡張に応じた提案モデルの性能改善の可能性を検討した。訓練データとテストデータを分離しなかった場合、提案モデルのR値は、3名に基づいて評価されたLMOベース研究のR値(-0.87から-0.98)と比較して高い(0.99)ことが確認された。スマートフォンを用いて記録されたPPGを使用した研究と比較すると、 R^2 値は特徴量ベースの研究のそれよりわずかに低かったが、波形ベースの研究より高い性能を示し、RMSEは他のすべての場合よりも

低かった。要約すると、本研究で開発されたモデルの性能は、既存の特徴量ベースの研究と同水準の性能を示し、波形を使用した研究と比較して改善された性能を示した。加えて、開発されたモデルは、訓練セットにおいて、年齢との非常に高い相関係数($R=0.99$)および決定係数($R^2=0.98$)、1.5歳という低いMAE、および2歳のRMSEを示し、これはテストセットの結果と比較して大きな乖離を示している。訓練セットの結果は、より大きな被験者間変動と過学習に帰することができるものの、既存の回帰モデルの結果と比較して、本研究で提案された1次元CNNベースのモデルがはるかに優れた表現力を持つことが確認できる。加えて、過学習は一般にデータが増加するにつれて緩和されうするため、データの拡張に伴う性能改善が期待できる。本研究のもう一つの利点は、別個の特徴抽出プロセスなしに、波形をそのまま使用することである。このように、特徴量ベースの研究と比較して、波形を使用する研究は、特徴点検出の負担がより少なく、特徴点の誤検出による誤差が低減されるという利点があり、より正確で安定した結果を提供する上で有利である。

Table 5(表5) ハイパーパラメータに応じたモデル性能

評価指標	平均±SD(範囲)
相関係数(R)	0.59±0.01 (0.55 – 0.61)
決定係数(R^2)	0.34±0.02 (0.30 – 0.37)
平均絶対誤差(歳)	8.4±0.1 (8.2 – 8.6)
二乗平均平方根誤差(歳)	10.3±0.2 (10.0 – 10.6)

Grad-CAM Grad-CAM(考察)

Grad-Camの結果については、セグメントの中央であるPPGの収縮期ピークおよび拡張期ピークを含む範囲における重みがより高く、Pulse_{onset}近傍の端における重みがより低いことが見て取れる。しかしながら、セグメンテーションの過程で脈波立ち上がり近傍の波形が切り取られたため、この結果のみから、脈波立ち上がりが血管老化の推定に寄与しないと結論することはできない。加えて、収縮期ピークが血管老化において重要な役割を果たすことは直観的に確認できるが、拡張期ピークの寄与を決定するためには、波形分解または微分波形による詳細な検証が必要である。加齢の進行に伴うGrad-Cam重要度の変化は、加齢に応じた左室収縮パターンまたは反射波の変化によって引き起こされている可能性があるかと推定される。特に、加齢の進行に伴う中間重要度区間(黄色)の増加は、反射波の急速な戻りに関係している可能性がある。

結論 Conclusion

われわれは、PPG原波形に深層学習を適用することによって血管老化を評価し、XAIを用いて、PPG波形のどの形状が血管老化の評価に寄与するかを同定する方法を提案した。結論として、特徴点検出プロセスを省略し原波形そのもののみを使用したにもかかわらず、提案された深層学習ベースの血管老化評価技術の性能は、既存の特徴量ベースの研究と同等であり、原波形ベースの研究よりも高かった。これは、深層学習がPPG波形から特徴を自動的に生成することができ、血管老化評価において、経験的かつ手動で検出された特徴を上回る、より高い有意性を持ちうることを示唆している。深層学習技術は、データの拡張に応じて、血管老化の評価においてより改善された性能を持つことが期待される。本研究の結果は、PPGを用いた血管老化評価の可能性を示唆するのみならず、XAIに基づく結果解釈を通じて、PPGベースの血管老化評価の原理と根拠についての示唆をも提供するものであり、これはPPGに反映される血管老化の特性の解明に寄与する。

データ利用可能性 Data availability

本研究の過程で生成および/または解析されたデータセットは、施設内審査委員会のデータ開示の範囲により公開されていないが、合理的な要請に基づいて責任著者から入手可能である。

受付: 2022年2月8日、受理: 2022年6月21日

オンライン公開: 2022年7月5日

参考文献 References

参考文献リスト(文献1~37)は原文(英語)のままであり、翻訳対象(本文・図・表)に含まれないため本誌では省略した。本文中の上付き番号は原論文の参考文献番号に対応する。

著者の貢献 Author contributions

H.S.は、研究の構想と設計、文献検索、データ収集と解析、起草、執筆、および図の設計と作図に貢献した。B.M.C.は、臨床試験の設計、被験者募集、データ記録、起草、および執筆に貢献した。G.N.は、臨床試験の設計、被験者募集、およびデータ記録に貢献した。全著者が最終文書の批判的レビューに貢献した。

資金 Funding

本研究は、韓国教育部の資金による韓国研究財団(NRF)を通じた基礎科学研究プログラム(NRF-2018R1D1A3B07046442)の支援を受け、また、韓国保健福祉部の資金による韓国保健産業振興院(KHIDI)を通じた韓国保健技術R&Dプロジェクト(HI21C0011)の支援を受けた。

競合利益 Competing interests

著者らは、競合利益がないことを宣言する。

追加情報 Additional information

補足情報(Supplementary Information) オンライン版には、<https://doi.org/10.1038/s41598-022-15240-4>で入手可能な補足資料が含まれる。

連絡先(Correspondence) および資料の請求は、H.S.またはB.-M.C.宛とすること。

転載および許諾情報は www.nature.com/reprints で入手可能である。

出版社注記(Publisher's note) Springer Natureは、公開された地図における管轄権の主張および機関の所属に関して中立を保つ。

オープンアクセス(Open Access) 本論文は、Creative Commons Attribution 4.0 International License(表示4.0 国際ライセンス)の下でライセンスされている。このライセンスは、原著者および出典に適切なクレジットを与え、Creative Commonsライセンスへのリンクを提供し、変更が加えられたかどうかを示す限りにおいて、あらゆる媒体または形式における使用、共有、翻案、配布、および複製を許諾する。本論文の画像またはその他の第三者資料は、資料へのクレジット表記において別段の指示がない限り、論文のCreative Commonsライセンスに含まれる。資料が論文のCreative Commonsライセンスに含まれておらず、かつ意図された使用が法令の規定により許可されていないか、許可された使用を超える場合には、著作権者から直接許諾を得る必要がある。本ライセンスの写しを閲覧するには、<http://creativecommons.org/licenses/by/4.0/> を参照のこと。